

Hochschule Reutlingen (HHZ)
Fakultät Informatik
DBE24 - Artificial Intelligence
Sommersemester 2026
Prof. Dr. Alexander Rossmann

Automatische Spam- und Phishing-Erkennung in der E-Mail-Kommunikation

Eine Machine-Learning-Fallstudie am Beispiel der Mercedes-Benz AG

Verfasser:

Reich, Patrick

M.Sc. Digital Business Engineering

Matrkl. 820895

Patrick.Reich@Student.Reutlingen-University.de

Abgabetermin: 28.06.2026

Inhaltsverzeichnis

1 Unternehmensbeschreibung	1
2 Problem- und Fragestellungen	1
3 Einordnung in den Bereich Machine Learning.....	1
4 Datenbeschreibung und Datenerfassung	2
4.1 Erste Befunde der explorativen Datenanalyse	2
4.2 Datenqualität und Datenerfassung	4
5 Modellbildung, Datenanalyse und Algorithmen	4
5.1 Datenvorbereitung	4
5.2 Eingesetzte Algorithmen.....	4
5.3 Wichtigste Merkmale	4
6 Deployment.....	5
7 Evaluation	5
7.1 Schwellenwert-Optimierung.....	7
7.2 Limitationen	7
8 Datenbasierte Services	8
9 Relevante Effekte für das Unternehmen	8
9.1 Fazit und Ausblick.....	8
Literaturverzeichnis	9
Anhang	10

Abbildungsverzeichnis

Abb. 1: Verteilung der Zielvariable (Spam).....	2
Abb. 2: Wort-Häufigkeit: Spam vs. legitim.....	3
Abb. 3: Großbuchstaben-Nutzung nach Klasse.....	3
Abb. 4: Stärkste Korrelationen mit 'Spam'.....	3
Abb. 5: Top-12 Merkmale (Random Forest).....	5
Abb. 6: ROC-Kurven der Modelle	6
Abb. 7: Confusion-Matrix des Random Forest.....	7
Abb. 8: Precision-Recall-Trade-off	7

1 Unternehmensbeschreibung

Die vorliegende Fallstudie betrachtet die Mercedes-Benz AG, einen der weltweit führenden Premium-Automobilhersteller mit Sitz in Stuttgart. Die Mercedes-Benz AG ist eine 100-prozentige Tochtergesellschaft der Mercedes-Benz Group AG und verantwortet das weltweite Pkw- und Van-Geschäft mit Marken wie Mercedes-Benz, Mercedes-AMG und Mercedes-Maybach (Mercedes-Benz Group AG, 2024). Sie entstand 2019 im Zuge der Neuaufstellung des Konzerns, der weltweit über 160.000 Mitarbeitende beschäftigt und an zahlreichen Standorten in Deutschland (u. a. Sindelfingen, Bremen, Rastatt) und international produziert. In einem global tätigen Unternehmen dieser Größe ist die E-Mail ein zentraler Kommunikationskanal; täglich gehen unternehmensweit sehr große Mengen an Nachrichten ein.

Mit der zunehmenden Digitalisierung, etwa vernetzten Fahrzeugen und global verteilten Lieferketten, wächst zugleich die Bedrohung durch unerwünschte und schädliche E-Mails. Spam belastet die Produktivität der Mitarbeitenden und Phishing also der Versuch, über gefälschte Nachrichten an Zugangsdaten oder Geld zu gelangen, zählt zu den häufigsten Einfallstoren für Cyberangriffe und ist damit ein ernstes Risiko für ein Unternehmen mit wertvollem geistigem Eigentum. Vor diesem Hintergrund eignet sich die Mercedes-Benz AG als Fallbeispiel für den Einsatz datengetriebener Verfahren des maschinellen Lernens zur automatischen Klassifikation eingehender E-Mails. Die Fallstudie bildet dabei bewusst keine realen internen Prozesse oder E-Mail-Daten der Mercedes-Benz AG ab, sondern nutzt einen öffentlichen Datensatz als realitätsnahe Annäherung an einen übertragbaren Anwendungsfall.

2 Problem- und Fragestellungen

Das zentrale Problem ist die zuverlässige, automatische Trennung von Spam und legitimer Post. Eine rein manuelle oder regelbasierte Filterung stößt an Grenzen, weil sich Spam-Muster ständig ändern. Zugleich sind beide Fehlertypen kostspielig: Gelangt Spam in den Posteingang (übersehene Erkennung), drohen Zeitverlust und Sicherheitsrisiken; wird hingegen eine legitime Mail fälschlich blockiert (Fehlalarm), können wichtige Geschäftsinformationen verloren gehen.

Daraus ergeben sich folgende Fragestellungen:

- **F1:** Lässt sich aus messbaren Merkmalen einer E-Mail (Wort- und Zeichenhäufigkeiten) zuverlässig vorhersagen, ob es sich um Spam handelt?
- **F2:** Welche Merkmale sind die stärksten Spam-Indikatoren?
- **F3:** Welches Machine-Learning-Verfahren bietet die beste Balance aus Erkennungsrate und niedriger Fehlalarmquote?
- **F4:** Welcher betriebliche Nutzen ergibt sich aus dem produktiven Einsatz?

3 Einordnung in den Bereich Machine Learning

Maschinelles Lernen ist ein Teilgebiet der Künstlichen Intelligenz, das Algorithmen befähigt, aus historischen Daten Muster zu lernen und auf neue Daten anzuwenden (Russell & Norvig, 2016; Ertel, 2016).

Die vorliegende Aufgabe ist dem überwachten Lernen zuzuordnen: Für die historischen E-Mails ist bekannt, ob sie Spam sind oder nicht; diese gelabelte Zielvariable dient als Lernsignal. Da nur zwei Klassen unterschieden werden (Spam / legitim), handelt es sich um eine binäre Klassifikation.

Methodisch folgt die Arbeit dem CRISP-DM-Vorgehensmodell nach Shearer (2000) mit den Phasen Geschäftsverständnis, Datenverständnis, Datenvorbereitung, Modellierung, Evaluation und Deployment. Eingesetzt werden drei Verfahren unterschiedlicher Komplexität: die logistische Regression als interpretierbares Basismodell, der Random Forest als leistungsfähiges Ensembleverfahren sowie ein künstliches neuronales Netz (Multi-Layer-Perceptron). Neuronale Netze bilden die Grundlage moderner Deep-Learning-Ansätze (Aggarwal, 2018; Goodfellow et al., 2016); der wirtschaftliche Wert solcher KI-Anwendungen wird in der Managementliteratur betont (Kaplan & Haenlein, 2019).

4 Datenbeschreibung und Datenerfassung

Datengrundlage ist der öffentlich verfügbare Spambase-Datensatz aus dem UCI Machine Learning Repository (Hopkins et al., 1999). Er umfasst 4.601 reale E-Mails, die aus einem betrieblichen Mailsystem stammen, mit 57 numerischen Merkmalen und der binären Zielvariable. Die Merkmale gliedern sich in drei Gruppen: 48 Wort-Häufigkeiten (z. B. wie oft Begriffe wie free, money oder hp vorkommen), 6 Zeichen-Häufigkeiten (etwa Ausrufezeichen, Dollar- und Rautezeichen) sowie 3 Kennzahlen zur Großbuchstaben-Nutzung. Eine Übersicht findet sich im Anhang (Tab. A1). Da unternehmensinterne E-Mails der Mercedes-Benz AG sensibel und nicht öffentlich verfügbar sind, dient dieser reale, repräsentative Datensatz als realitätsnahe Grundlage, ohne reale interne Daten abzubilden.




Abb. 1: Verteilung der Zielvariable. Rund 39,4 % der E-Mails sind Spam.

Von den 4.601 E-Mails sind 1.813 Spam (39,4 %) und 2.788 legitim. Die Klassen sind damit nur leicht unausgewogen, günstiger als bei vielen anderen Anwendungsfällen. Der Datensatz enthält keine fehlenden Werte.

4.1 Erste Befunde der explorativen Datenanalyse

Die explorative Analyse zeigt klare, inhaltlich plausible Muster. Werbe- und Phishing-typische Wörter wie free, money, your, remove oder credit treten in Spam deutlich häufiger auf, während geschäfts- und personenbezogene Begriffe wie hp, george, meeting oder edu für legitime Mails sprechen (Abb. 2).




Abb. 2: Mittlere Worthäufigkeit in Spam- vs. legitimen E-Mails.

Auch die Schreibweise unterscheidet sich: Spam nutzt deutlich mehr Großbuchstaben (z. B. reißerische Betreffzeilen), wie der Vergleich der Großbuchstaben-Nutzung zeigt (Abb. 3).




Abb. 3: Großbuchstaben-Nutzung nach Klasse (logarithmiert).

Die Korrelationsanalyse bestätigt dies: Am stärksten positiv mit Spam korrelieren your, 000, remove, das Dollarzeichen sowie free; negativ (also legitim-typisch) sind hp, hpl und george (Abb. 4).




Abb. 4: Merkmale mit der stärksten Korrelation zur Zielvariable.

4.2 Datenqualität und Datenerfassung

Der Datensatz ist vollständig und konsistent; es sind keine fehlenden Werte enthalten, sodass keine Imputation erforderlich ist. Alle Merkmale liegen bereits in numerischer Form vor. In der Praxis würden die Merkmale automatisiert aus eingehenden E-Mails extrahiert (Häufigkeit definierter Wörter und Zeichen, Großbuchstaben-Statistiken) und dem Modell in Echtzeit am Mail-Gateway zugeführt.

5 Modellbildung, Datenanalyse und Algorithmen

5.1 Datenvorbereitung

Da alle 57 Merkmale bereits numerisch sind, entfällt ein Encoding kategorialer Variablen. Die Zielvariable wurde von den Eingangsmerkmalen getrennt und die Daten in einen Trainings- (80 %, 3.680 E-Mails) und einen Testdatensatz (20 %, 921 E-Mails) aufgeteilt. Die Aufteilung erfolgte stratifiziert, sodass die Spam-Quote in beiden Mengen identisch ist. Anschließend wurden alle Merkmale standardisiert; der Scaler wurde ausschließlich auf den Trainingsdaten angepasst und dann auf die Testdaten angewandt, um Datenleckagen zu vermeiden. Dies ist insbesondere für die logistische Regression und das neuronale Netz wichtig.

5.2 Eingesetzte Algorithmen

Logistische Regression. Lineares Klassifikationsverfahren, das die Spam-Wahrscheinlichkeit über eine logistische Funktion der gewichteten Merkmale schätzt. Sehr gut interpretierbar, da die Koeffizienten Richtung und Stärke jedes Einflusses angeben (Hosmer et al., 2013; Géron, 2020).

Random Forest. Ensembleverfahren aus vielen Entscheidungsbäumen, die auf zufälligen Teilstichproben trainiert und gemittelt werden. Erfasst nichtlineare Zusammenhänge, ist robust und liefert eine Merkmalswichtigkeit (James et al., 2021; Géron, 2020).

Künstliches neuronales Netz (MLP). Multi-Layer-Perceptron mit zwei verborgenen Schichten (64 und 32 Neuronen), das komplexe, nichtlineare Muster lernt (Aggarwal, 2018). Early Stopping verhindert Überanpassung.

Bei logistischer Regression und Random Forest wurde der leichten Klassenungleichheit über eine gewichtete Verlustfunktion (`class_weight = balanced`) begegnet.

5.3 Wichtigste Merkmale

Die vom Random Forest ermittelte Merkmalswichtigkeit (Abb. 5) bestätigt die EDA: das Ausrufezeichen, das Dollarzeichen, die Großbuchstaben-Kennzahlen sowie die Wörter `remove`, `your` und `free` sind die stärksten Spam-Indikatoren. Die Koeffizienten der logistischen Regression bestätigen die Richtung: lange Großbuchstabenfolgen, das Dollar- und Rautezeichen, `remove` und `000` erhöhen die Spam-Wahrscheinlichkeit, während firmen- und personenbezogene Begriffe wie `george`, `hp`, `cs`, `edu` und `meeting` sie stark senken. Dieses Muster spiegelt den betrieblichen Ursprung der Daten wider und ist inhaltlich gut nachvollziehbar.




Abb. 5: Die zwölf wichtigsten Merkmale (Random Forest).

6 Deployment

Für den produktiven Einsatz wird das trainierte Modell zusammen mit der Vorverarbeitung serialisiert und als Dienst direkt am E-Mail-Gateway bereitgestellt (z. B. als REST-Schnittstelle, gekapselt in einem Container). Jede eingehende Nachricht wird in Echtzeit bewertet: Bei hoher Spam-Wahrscheinlichkeit wird sie in einen Quarantäne-Ordner verschoben, bei niedriger in den Posteingang zugestellt. Besonders kritische Treffer werden quarantänisiert statt gelöscht, damit Fehlalarme von den Nutzenden überprüft werden können.

Da sich Spam- und Phishing-Muster fortlaufend ändern (Konzeptdrift), sind ein kontinuierliches Monitoring der Erkennungsgüte sowie ein regelmäßiges Re-Training mit neuen, gelabelten E-Mails erforderlich (MLOps). Rückmeldungen der Nutzenden (etwa über eine Als-Spam-markieren-Funktion) liefern dabei wertvolle neue Trainingsdaten.

Umgesetzter Prototyp. Das Deployment wurde im Rahmen dieser Arbeit prototypisch realisiert. Das trainierte Modell wird gemeinsam mit dem Scaler und der Merkmalsreihenfolge mittels joblib serialisiert (Datei spam_model.joblib) und kann so ohne erneutes Training geladen werden. Eine lauffähige REST-Schnittstelle ist in der beigefügten Datei app.py (FastAPI) implementiert: Sie lädt das Modell und stellt einen /predict-Endpoint bereit, an den die 57 Merkmale einer E-Mail gesendet werden und der ein Spam-Urteil samt Wahrscheinlichkeit zurückgibt. Das Notebook demonstriert zusätzlich das Laden des Modells und die Klassifikation einer Beispiel-E-Mail. Der lokale Start erfolgt über `uvicorn app:app`.

7 Evaluation

Die Bewertung erfolgte auf dem separaten Testdatensatz (921 E-Mails). Für einen Spam-Filter sind beide Fehlertypen relevant: Übersehene Spam (False Negative) bedeutet Sicherheits- und Zeitverlust, eine fälschlich blockierte legitime Mail (False Positive) kann geschäftsschädigend sein. Daher betrachten wir Precision, Recall und F1 sowie die schwellenunabhängige ROC-AUC. Tabelle 1 fasst die Ergebnisse zusammen.

Modell	Accuracy	Precision	Recall	F1	ROC-AUC
Logistische Regression	0,922	0,890	0,915	0,902	0,970
Random Forest	0,947	0,949	0,915	0,931	0,983
Neurales Netz (MLP)	0,932	0,914	0,912	0,913	0,976

Tab. 1: Vergleich der Modellgüte auf dem Testdatensatz (Schwelle 0,5).

Alle drei Modelle erreichen eine sehr hohe Trennschärfe (ROC-AUC zwischen 0,97 und 0,98). Der Random Forest erzielt mit Abstand die besten Werte, höchste Accuracy (0,947), höchste Precision (0,949), höchster F1-Score (0,931) und höchste ROC-AUC (0,983). Da er Spam zuverlässig erkennt und zugleich nur sehr wenige legitime Mails fälschlich blockiert, wird er als bevorzugtes Modell gewählt.




Abb. 6: ROC-Kurven der drei Modelle.

Die Confusion-Matrix des Random Forest (Abb. 7) verdeutlicht die Güte: Von 363 tatsächlichen Spam-Mails im Test werden 332 korrekt erkannt (richtig-positiv) und nur 31 übersehen (falsch-negativ). Von 558 legitimen Mails werden lediglich 18 fälschlich als Spam markiert (falsch-positiv). Das entspricht einer Erkennungsrate von 91,5 % bei einer Fehlalarmquote von nur 3,2 %.




Abb. 7: Confusion-Matrix des Random Forest (Schwelle 0,5).

7.1 Schwellenwert-Optimierung

Die Standardschwelle von 0,5 ist nicht zwingend optimal. Abb. 8 zeigt den Verlauf von Precision, Recall und F1 über alle Schwellen. Die Schwelle wirkt als Steuerungshebel: Eine niedrigere Schwelle erhöht den Recall (mehr Spam wird gefangen), aber auch die Fehlalarme; eine höhere Schwelle umgekehrt. Der F1-optimale Schwellenwert liegt bei rund 0,44 und hebt den F1-Score leicht von 0,931 auf 0,938. Im Betrieb würde man die Schwelle bewusst eher vorsichtig wählen, um legitime Mails nicht zu blockieren, und kritische Fälle in die Quarantäne leiten.




Abb. 8: Precision-Recall-Trade-off über die Entscheidungsschwelle.

Auf ein Oversampling (SMOTE) wurde bewusst verzichtet, da der Datensatz mit ~39 % Spam nur leicht unbalanciert ist und die klassengewichtete Konfiguration ausreicht, das hält das Modell einfacher und nachvollziehbarer.

7.2 Limitationen

Die Ergebnisse sind vor dem Hintergrund einiger Einschränkungen zu interpretieren. Erstens stammen die Daten aus einem bestimmten betrieblichen Kontext (u. a. erkennbar an firmenspezifischen Begriffen wie hp oder george); auf ein anderes Unternehmen müssten Merkmale und Modell neu kalibriert werden. Zweitens entwickeln sich Spam-Muster fortlaufend weiter (Konzeptdrift), weshalb ein einmal trainiertes Modell ohne Re-Training an Güte verliert. Drittens beruhen die Merkmale auf einfachen Häufigkeiten und erfassen keine semantischen Zusammenhänge. Zukünftige Arbeiten könnten moderne Sprachmodelle (NLP/Transformer), eine kostenbasierte Schwellenwahl sowie erklärbare KI (SHAP) einbeziehen.

8 Datenbasierte Services

Aus dem Modell lassen sich mehrere datenbasierte Services ableiten, die über die reine Klassifikation hinaus Wert schaffen (Provost & Fawcett, 2013). Erstens der eigentliche Spam-Filter, der eingehende Mails automatisch sortiert. Zweitens eine Phishing-Frühwarnung für das IT-Security-Team, die auffällige Wellen verdächtiger Nachrichten meldet. Drittens ein Quarantäne-Self-Service, über den Mitarbeitende geblockte Mails selbst prüfen und freigeben können. Viertens ein Security-Dashboard, das Spam-Aufkommen, Erkennungsrate und Fehlalarme über die Zeit visualisiert.

Da das Modell Wahrscheinlichkeiten liefert, lassen sich Nachrichten zudem nach Risikograd priorisieren. Perspektivisch können die Services um erklärbare Hinweise erweitert werden (etwa: als Spam erkannt wegen Häufung von Dollarzeichen, Ausrufezeichen und dem Wort remove), was die Akzeptanz erhöht.

9 Relevante Effekte für das Unternehmen

Der Nutzen lässt sich an einer vereinfachten Rechnung verdeutlichen. Nimmt man an, dass jede durchgelassene Spam-Mail durchschnittlich 2,00 EUR (verlorene Arbeitszeit und Sicherheitsrisiko) und jede fälschlich blockierte legitime Mail 1,50 EUR (Nacharbeit) kostet, so verursacht der gesamte Spam-Eingang ohne Filter auf der Testmenge rund 726 EUR. Mit dem Random-Forest-Filter sinken die Kosten auf etwa 89 EUR, eine Ersparnis von rund 637 EUR allein auf den 921 Test-Mails. Hochgerechnet auf das tägliche, deutlich größere Mailaufkommen eines Großkonzerns wie der Mercedes-Benz AG ist das Einsparpotenzial erheblich.

Neben dem direkten finanziellen Effekt ergeben sich qualitative Vorteile: ein geringeres Phishing- und damit Sicherheitsrisiko, entlastete Mitarbeitende und IT, sowie eine höhere Konzentration auf wertschöpfende Tätigkeiten. Voraussetzung für den verantwortungsvollen Betrieb sind Datenschutz (Vertraulichkeit der E-Mail-Inhalte), Transparenz gegenüber den Mitarbeitenden und eine niedrige Fehlalarmquote, damit keine geschäftsrelevanten Mails verloren gehen.

9.1 Fazit und Ausblick

Die Fallstudie zeigt, dass sich Spam mit Standardverfahren des maschinellen Lernens sehr zuverlässig erkennen lässt (ROC-AUC $\approx 0,98$). Die wichtigsten Signale sind Sonderzeichen, Großschreibung und typische Werbewörter. Der Random Forest bietet die beste Balance aus hoher Erkennungsrate (91,5 %) und niedriger Fehlalarmquote (3,2 %) und eignet sich daher für den produktiven Einsatz. Die Fragestellungen F1 bis F4 konnten damit beantwortet werden. Für die Weiterentwicklung empfehlen sich Hyperparameter-Optimierung, eine kostenbasierte Schwellenwert-Wahl, der Einsatz semantischer NLP-Verfahren sowie ein produktives Monitoring auf Konzeptdrift.

Literaturverzeichnis

- Aggarwal, C. C. (2018). Neural Networks and Deep Learning: A Textbook. Springer.
- Ertel, W. (2016). Grundkurs Künstliche Intelligenz: Eine praxisorientierte Einführung (4. Aufl.). Springer Vieweg.
- Géron, A. (2020). Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow (2. Aufl.). O'Reilly.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.
- Hopkins, M., Reeber, E., Forman, G., & Suermondt, J. (1999). Spambase Data Set. UCI Machine Learning Repository. <https://archive.ics.uci.edu/dataset/94/spambase>
- Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). Applied Logistic Regression (3. Aufl.). Wiley.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An Introduction to Statistical Learning (2. Aufl.). Springer.
- Kaplan, A., & Haenlein, M. (2019). Siri, Siri, in my hand: Who's the fairest in the land? On the interpretations, illustrations, and implications of artificial intelligence. Business Horizons, 62(1), 15-25.
- Mercedes-Benz Group AG (2024). Unternehmensprofil. <https://group.mercedes-benz.com>
- Provost, F., & Fawcett, T. (2013). Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking. O'Reilly Media.
- Russell, S. J., & Norvig, P. (2016). Artificial Intelligence: A Modern Approach. Pearson Education.
- Shearer, C. (2000). The CRISP-DM model: The new blueprint for data mining. Journal of Data Warehousing, 5(4), 13-22.

Anhang

Der vollständige, ausführbare Programmcode ist im beigefügten Jupyter Notebook *Spam_Detection.ipynb* dokumentiert; der Datensatz liegt als *spambase.csv* bei (öffentlicher Spambase-Datensatz, UCI / Hopkins et al. 1999). Der Deployment-Prototyp besteht aus dem serialisierten Modell *spam_model.joblib* und der REST-API *app.py* (FastAPI).

Tab. A1: Merkmalsgruppen des Datensatzes

Merkmalsgruppe	Beschreibung	Anzahl
Wort-Häufigkeiten	% der Wörter, die einem bestimmten Begriff entsprechen (z. B. free, money, remove, your, hp, george)	48
Zeichen-Häufigkeiten	% bestimmter Sonderzeichen (; ([! \$ #)	6
Großbuchstaben	capitalAve (Ø Lauflänge), capitalLong (längster Lauf), capitalTotal (Summe)	3
Zielvariable (spam)	1 = Spam, 0 = legitime E-Mail	1